

Analisi e Classificazione di Segnali EEG per il Riconoscimento dello Stato Oculare

Report - Machine Learning

Serena Celeste Antonini - 900452

Valeria Crippa - 906306

Indice

1	Descrizione del dominio e degli obiettivi	4
2	Scelte di progettazione, ipotesi e assunzioni	4
2.1	Scelte di progettazione	4
2.1.1	Scelta dei modelli	4
2.1.2	Gestione e partizionamento dei dati	5
2.1.3	Strategia di inclusione delle feature	5
2.1.4	Preprocessing	5
2.1.5	Analisi della dimensionalità (PCA)	6
2.1.6	Protocollo di validazione statistica	6
2.2	Ipotesi e assunzioni	6
2.2.1	Ipotesi fisiologiche e fisiche	6
2.2.2	Assunzioni sui dati	7
3	Descrizione dell'analisi esplorativa (EDA)	7
3.1	Panoramica del dataset	7
3.2	Qualità dei dati	8
3.3	Statistiche descrittive e analisi degli outlier	8
3.4	Analisi delle correlazioni e della covarianza	10
3.4.1	Analisi pre-cleaning	10
3.4.2	Analisi post-cleaning	10
3.5	Analisi della dimensionalità (PCA)	11
4	Descrizione e logica dei modelli di Machine Learning scelti	13
4.1	Gaussian Naive Bayes (con PCA)	13
4.2	Decision Tree	13
4.3	Support Vector Machines (SVM)	13
5	Campagna sperimentale	14
5.1	Preparazione del dataset	14
5.2	Preprocessing e Pipeline	14
5.3	Definizione della Baseline	15
5.4	Strategia di ottimizzazione dei modelli (Hyperparameter Tuning)	15
5.5	Protocollo di Valutazione sul Test Set	16
5.6	Valutazione della Capacità Discriminante (Curve ROC e AUC)	16
5.7	Analisi dell'Efficienza Computazionale	16
5.8	Validazione Statistica (Repeated Stratified Cross-Validation)	16
6	Analisi dei risultati	16
6.1	Modello di Baseline	17
6.2	Gaussian Naive Bayes	17
6.3	Decision Trees	17
6.3.1	Albero Completo	17
6.3.2	Ottimizzazione tramite Cost Complexity Pruning	17
6.3.3	Risultati dell'Albero Finale (Post-Pruning)	18
6.4	Support Vector Machines (SVM)	19
6.4.1	SVM con Kernel Lineare	19
6.4.2	SVM con Kernel RBF	19
6.5	Analisi Comparativa	20
6.5.1	Confronto delle Performance sul Test Set	20
6.5.2	Analisi dell'Efficienza Computazionale	20
6.5.3	Analisi della Capacità Discriminante (Curve ROC)	20
6.5.4	Validazione Statistica e Discussione Critica dell'Anomalia Ricontrata	21

7	Conclusioni e riflessioni critiche	22
7.1	Il Trade-off tra Precision e Recall	22
7.2	Scelta del modello in base al contesto applicativo	22
7.3	Sviluppi Futuri	23

1 Descrizione del dominio e degli obiettivi

Questo progetto consiste nell'analizzare e classificare lo stato oculare di un soggetto (*occhi aperti* vs *occhi chiusi*) a partire da segnali elettroencefalografici (EEG).

L'elettroencefalografia (EEG) è una tecnica non invasiva che misura l'attività elettrica cerebrale tramite elettrodi posizionati sul cuoio capelluto. I segnali EEG sono ampiamente utilizzati nel campo delle Brain-Computer Interface (BCI), sistemi che permettono la comunicazione diretta tra cervello e dispositivi esterni senza l'utilizzo della muscolatura.

La capacità di rilevare automaticamente se un soggetto ha gli occhi chiusi rappresenta un indicatore critico per diversi ambiti applicativi:

- **Sistemi di monitoraggio della vigilanza:** identificazione di cali di attenzione o dell'insorgenza del sonno in operatori impegnati in attività critiche, come conducenti di veicoli o piloti.
- **Diagnostica clinica:** supporto all'analisi di patologie neurologiche e disturbi del sonno.
- **Interazione uomo-macchina:** possibilità per persone con disabilità motorie di interagire con dispositivi esterni attraverso il controllo volontario del battito o della chiusura delle palpebre.

Dal punto di vista tecnico, il dominio presenta sfide significative. I segnali EEG sono serie temporali caratterizzate da un basso rapporto segnale-rumore e risultano spesso contaminati da artefatti di origine biologica o tecnica.

Il dataset utilizzato per l'addestramento e la validazione dei modelli è reperibile pubblicamente su Kaggle ed è denominato *EEG Eye State Dataset*.

L'obiettivo principale del progetto consiste nella costruzione e nel confronto di modelli predittivi robusti e affidabili in grado di classificare lo stato oculare a partire dai segnali EEG, bilanciando accuratezza e capacità di generalizzazione.

Per raggiungere tale obiettivo è stato necessario:

1. Condurre un'analisi esplorativa approfondita dei dati al fine di comprenderne la struttura e individuare eventuali anomalie.
2. Applicare tecniche di pre-processing adeguate per la gestione degli outlier e la preparazione dei dati alla fase di modellazione.
3. Addestrare e ottimizzare modelli di classificazione supervisionata basati su differenti paradigmi:
 - approccio probabilistico (*Naive Bayes*);
 - approccio gerarchico (*Decision Tree*);
 - approccio geometrico (*Support Vector Machine - SVM*).
4. Confrontare le prestazioni dei modelli al fine di identificare la soluzione più adatta al problema in esame.

2 Scelte di progettazione, ipotesi e assunzioni

2.1 Scelte di progettazione

La progettazione dell'esperimento è stata guidata dalla necessità di confrontare modelli caratterizzati da differenti logiche di apprendimento (probabilistiche, gerarchiche e geometriche) per la classificazione di segnali bioelettrici complessi. L'obiettivo è stato quello di ottimizzare la pipeline di preprocessing e valutazione in funzione delle caratteristiche specifiche di ciascun algoritmo.

2.1.1 Scelta dei modelli

Gaussian Naive Bayes Il modello Gaussian Naive Bayes è stato selezionato come benchmark probabilistico iniziale. L'algoritmo si basa sull'assunzione matematica di indipendenza condizionale tra le variabili predittive. Per soddisfare rigorosamente questo requisito teorico, il modello non è stato addestrato sui 14 canali EEG originali ma sulle prime 10 componenti principali estratte tramite PCA. Questo garantisce di operare in uno spazio di vettori ortogonali e totalmente indipendenti, massimizzando l'efficacia del classificatore.

Decision Tree L'Albero Decisionale è stato scelto per la sua capacità di modellare relazioni non lineari attraverso una struttura gerarchica di regole decisionali. Un ulteriore vantaggio è rappresentato dall'elevata interpretabilità del modello, che consente di identificare quali sensori EEG contribuiscono maggiormente al processo decisionale. Inoltre, l'impiego della tecnica di *Cost Complexity Pruning* ha permesso di controllare la complessità dell'albero, limitando il rischio di adattamento al rumore presente nel segnale.

Support Vector Machines Le Support Vector Machines (SVM) sono state introdotte per valutare la possibilità di separare le classi mediante un confine decisionale geometrico nello spazio delle feature. In particolare, l'utilizzo del kernel Radial Basis Function (RBF) è finalizzato a catturare relazioni non lineari e regioni di sovrapposizione tra le classi.

2.1.2 Gestione e partizionamento dei dati

La gestione dei dati è stata progettata in modo da rispettare la natura stocastica dei segnali EEG e garantire una netta separazione tra la fase di sviluppo dei modelli e la fase di valutazione finale.

Il dataset presenta una suddivisione nativa tra *Training Set* e *Test Set*, mantenuta per assicurare un confronto standardizzato tra i modelli.

Integrità del Test Set Il Test Set è stato utilizzato esclusivamente per la valutazione finale delle prestazioni. Tutte le attività di analisi, selezione delle feature e ottimizzazione degli iperparametri sono state svolte utilizzando unicamente i dati di addestramento, evitando qualsiasi fenomeno di *data leakage*.

Introduzione del Validation Set Nella fase iniziale di partizionamento dei dati, oltre alla separazione del Test Set, è stato preventivamente isolato un Validation Set pari al 20% del Training Set. Questo sottoinsieme indipendente è stato impiegato nello specifico durante lo sviluppo dell'Albero Decisionale: esso ha consentito di stimare il parametro di complessità α necessario per la fase di *pruning*, evitando di calibrare l'iperparametro sui dati usati per l'addestramento.

2.1.3 Strategia di inclusione delle feature

L'analisi preliminare del dataset tramite Principal Component Analysis (PCA) ha evidenziato come il 95% della variabilità totale del segnale sia distribuito su 10 componenti principali. Nonostante questa indicazione di parziale ridondanza dei sensori, si è scelto di adottare una strategia asimmetrica per l'inclusione delle feature a seconda del modello:

- **Alberi Decisionali e SVM:** Si è scelto di mantenere l'intero insieme dei 14 sensori EEG originali. Per il Decision Tree, questo garantisce la massima interpretabilità clinica e topografica, permettendo all'algoritmo di selezionare autonomamente i sensori fisici più informativi. Per le SVM, la scelta è motivata dalla loro intrinseca robustezza nella gestione di spazi ad alta dimensionalità.
- **Naive Bayes:** Come anticipato, le feature sono state compresse e ridotte alle 10 componenti principali ortogonali, in modo da rispettare l'assunzione di indipendenza condizionale richiesta dall'algoritmo.

2.1.4 Preprocessing

Una fase fondamentale del progetto ha riguardato la definizione di una strategia di preprocessing adeguata alla natura rumorosa dei segnali EEG.

Gestione degli outlier mediante IQR L'analisi esplorativa ha evidenziato la presenza di valori anomali estremamente elevati, incompatibili con l'attività fisiologica cerebrale e riconducibili a probabili artefatti tecnici o biologici.

Per questo motivo è stata adottata una procedura basata sull'Interquartile Range (IQR):

- sul Training Set sono state eliminate tutte le osservazioni esterne all'intervallo

$$[Q_1 - 1.5 \cdot IQR, Q_3 + 1.5 \cdot IQR]$$

ottenendo un sottoinsieme di 6462 campioni dopo la rimozione di 1522 osservazioni anomale;

- sul Test Set non è stata effettuata alcuna eliminazione di record. I valori estremi sono stati invece ricondotti ai limiti calcolati sul Training Set mediante una procedura di *clipping*.

Pipeline e prevenzione del Data Leakage Per tutti i modelli che richiedono la standardizzazione o la trasformazione delle feature (SVM e Naive Bayes), le operazioni sono state rigidamente incapsulate utilizzando la classe `Pipeline` di Scikit-Learn. Questo approccio architetturale assicura che trasformatori come lo `StandardScaler` e la PCA vengano calibrati (*fit*) esclusivamente sui dati di training del momento e solo successivamente applicati ai dati di validazione e test. Essendo le `Pipeline` impiegate anche all'interno della Cross-Validation, ogni fold ricalcola i parametri di scalatura sui propri dati di training, azzerando matematicamente il rischio di *data leakage*. Al contrario, il Decision Tree, essendo intrinsecamente invariante alla scala, riceve direttamente in input i dati grezzi, preservando la leggibilità delle soglie in microvolt.

Analisi della varianza e della correlazione Successivamente alla pulizia dei dati è stata effettuata una verifica dell'informatività delle feature mediante *Variance Threshold*.

Con una soglia pari a 0.01, tutti i 14 elettrodi sono risultati sufficientemente informativi e nessuna feature è stata eliminata.

L'analisi della matrice di correlazione ha mostrato l'assenza di coppie di variabili con correlazione superiore alla soglia critica di 0.95, confermando che ciascun sensore fornisce un contributo informativo distinto. La correlazione più elevata osservata è AF3/AF4 ($r = 0.86$), fisiologicamente coerente con la vicinanza anatomica degli elettrodi.

2.1.5 Analisi della dimensionalità (PCA)

È stata applicata la Principal Component Analysis (PCA) con l'obiettivo di studiare la struttura interna del dataset e valutare la riduzione della dimensionalità. Il modello PCA è stato addestrato esclusivamente sui dati di training standardizzati. Come verrà mostrato in dettaglio nel prossimo capitolo, la prima componente spiega solo il 46.42% della varianza. Per raggiungere il 95% è necessario mantenere 10 componenti, confermando che l'informazione discriminante è distribuita su quasi tutti gli elettrodi. Inoltre, la proiezione sulle prime due componenti ha confermato la natura non linearmente separabile del problema, giustificando l'impiego successivi di modelli non lineari come SVM RBF e Decision Tree.

2.1.6 Protocollo di validazione statistica

Per garantire una valutazione robusta delle prestazioni dei modelli è stato adottato un protocollo di validazione iterativo.

Campionamento stratificato In ogni iterazione la proporzione tra le classi è stata mantenuta costante, preservando la distribuzione originale del dataset (56.1% Open e 43.9% Closed).

Repeated Stratified Cross-Validation La valutazione è stata effettuata utilizzando la tecnica `RepeatedStratifiedKFold` con 10 fold ripetuti 5 volte, per un totale di 50 valutazioni indipendenti per ciascun modello.

Questa procedura ha consentito di stimare intervalli di confidenza al 95% e verificare la significatività statistica delle differenze osservate tra i modelli.

2.2 Ipotesi e assunzioni

2.2.1 Ipotesi fisiologiche e fisiche

La classificazione dello stato oculare si basa sull'ipotesi che l'apertura e la chiusura degli occhi producano variazioni sistematiche nell'attività elettrica rilevabile dai sensori EEG, riflettendosi direttamente sui valori numerici acquisiti.

Ipotesi sulla topografia dei sensori Si assume che la dislocazione spaziale dei sensori sullo scalpo catturi segnali differenziati ma complementari. Ad esempio, si ipotizza che gli elettrodi frontali (come AF3 e AF4) siano maggiormente sensibili ai potenziali elettrici generati dai movimenti delle palpebre, mentre gli elettrodi posteriori (come O1 e O2) registrino l'attività della corteccia visiva. Questa ipotesi giustifica l'utilizzo combinato dell'intero set di feature, assumendo che lo stato oculare sia un'informazione distribuita globalmente piuttosto che confinata in un singolo canale.

Ipotesi sulla distinzione tra segnale e rumore Osservando preliminarmente l'ordine di grandezza dei dati, si assume che il vero segnale fisiologicamente d'interesse sia contenuto in un intervallo di potenziale elettrico ristretto e stabile, compreso approssimativamente tra 3.900 e $4.700\mu V$. Si ipotizza di conseguenza che valori che si discostano in modo macroscopico da questo range (raggiungendo picchi di centinaia di migliaia di microvolt) siano da interpretare esclusivamente come artefatti di acquisizione e non come variazioni biologiche utili alla classificazione.

Ipotesi sulla geometria dei dati (Non linearità) Data la complessità delle interazioni elettriche e la ridondanza parziale tra canali adiacenti, si assume che la mappatura tra le feature EEG e la variabile target sia intrinsecamente non lineare. Si ipotizza pertanto che un confine decisionale flessibile (come quello generato da alberi decisionali o da una SVM con kernel RBF) sia metodologicamente necessario per separare le classi, rispetto alla ricerca di un singolo iperpiano lineare.

2.2.2 Assunzioni sui dati

Per l'addestramento e la validazione dei modelli sono state adottate le seguenti assunzioni:

- **Indipendenza temporale (I.I.D.):** per semplicità ogni osservazione viene considerata indipendente dalle altre, nonostante l'EEG rappresenti un segnale temporale continuo.
- **Sincronia dei sensori:** si assume che i valori riportati in ciascuna osservazione siano stati acquisiti simultaneamente dai 14 elettrodi.
- **Affidabilità delle etichette:** le classi target (0 = `Open`, 1 = `Closed`) sono considerate corrette e rappresentano la *ground truth* del problema.
- **Generalizzabilità tra soggetti:** si assume che i pattern EEG associati allo stato oculare siano sufficientemente universali da consentire una generalizzazione del modello oltre le specifiche sessioni di acquisizione presenti nel dataset.

3 Descrizione dell'analisi esplorativa (EDA)

L'analisi esplorativa dei dati (*Exploratory Data Analysis*, EDA) ha l'obiettivo di comprendere la struttura, la qualità e le caratteristiche principali del dataset prima della fase di modellazione. Nel contesto dei segnali EEG, questa fase risulta particolarmente importante per individuare eventuali artefatti tecnici e verificare la capacità discriminante dei sensori rispetto allo stato oculare del soggetto.

3.1 Panoramica del dataset

L'analisi esplorativa è stata condotta sull'intero dataset composto da 14.980 osservazioni, ottenuto dall'unione del Training Set (9.980 campioni) e del Test Set (5.000 campioni) esclusivamente a fini esplorativi. Tutte le operazioni di preprocessing e addestramento dei modelli sono state invece effettuate unicamente sui dati di training.

Il dataset contiene 14 feature numeriche continue, corrispondenti ai segnali EEG espressi in microvolt (μV) rilevati dai seguenti elettrodi:

AF3, F7, F3, FC5, T7, P7, O1, O2, P8, T8, FC6, F4, F8, AF4.

La variabile target è binaria e rappresenta lo stato oculare del soggetto:

- 0: occhio aperto (*Open*);
- 1: occhio chiuso (*Closed*).

La distribuzione delle classi evidenzia un lieve sbilanciamento:

- **Occhio aperto:** 56.1% dei campioni;
- **Occhio chiuso:** 43.9% dei campioni.

Per preservare tale distribuzione in tutte le fasi sperimentali è stata adottata una strategia di campionamento stratificato, garantendo la rappresentatività delle classi nei diversi sottoinsiemi utilizzati durante l'addestramento e la valutazione.

3.2 Qualità dei dati

L'analisi preliminare della qualità del dataset ha evidenziato diversi aspetti rilevanti per la successiva fase di preprocessing.

Integrità dei dati Il dataset non presenta valori mancanti (*missing values*) in nessuna delle feature disponibili. Questa caratteristica elimina la necessità di procedure di imputazione e garantisce la completezza delle osservazioni per tutti i sensori EEG.

Scale e distribuzioni Sebbene tutte le feature presentino valori medi comparabili, generalmente compresi tra 4.000 e 4.500 μV , le distribuzioni mostrano comportamenti molto differenti nelle code.

Alcuni sensori presentano una variabilità relativamente contenuta, mentre altri evidenziano la presenza di picchi estremamente elevati. Questa eterogeneità rende necessaria una fase di standardizzazione, al fine di evitare che i canali maggiormente rumorosi influenzino in modo sproporzionato il processo di apprendimento dei modelli.

3.3 Statistiche descrittive e analisi degli outlier

Le statistiche descrittive mostrano che le distribuzioni delle feature sono caratterizzate da una forte asimmetria e dalla presenza di valori estremi incompatibili con la fisiologia umana.

Presenza di artefatti Alcuni sensori registrano valori massimi particolarmente elevati:

- AF4: 715.897 μV .
- FC5: 642.564 μV ;
- O1: 567.179 μV ;

Tali valori risultano enormemente superiori rispetto alle rispettive mediane, che si collocano intorno ai 4.300 μV , suggerendo la presenza di artefatti tecnici o interferenze elettroniche.

Differenza tra media e mediana La presenza degli outlier influenza significativamente le statistiche classiche. Ad esempio, nel canale FC5 la media risulta alterata dai picchi anomali, la deviazione standard (5216.41) è enormemente superiore rispetto a quella di sensori come T7 (39.92) o FC6 (38.51), evidenziando una dispersione artificiale causata dagli outlier non rappresentativa del comportamento reale del segnale.

Questi risultati confermano la necessità di una procedura rigorosa di trattamento degli outlier. In particolare, è stato adottato il metodo basato sull'Interquartile Range (IQR), seguito dalla standardizzazione delle feature.

Distribuzione delle feature EEG

La Figura 1 mostra la distribuzione delle 14 feature EEG.

Per poter vedere la presenza di valori estremi molto rari rispetto alla massiccia concentrazione di dati nel range fisiologico, si è resa necessaria l'applicazione di una scala logaritmica sull'asse delle ordinate (Y).

Come si evince dai grafici, la quasi totalità delle osservazioni è concentrata in un intervallo orizzontale relativamente ristretto. Tuttavia, la presenza di pochissimi artefatti provoca una forte dilatazione dell'asse delle ascisse (X). Grazie alla scala logaritmica, è possibile notare visivamente come questi outlier estremi siano rappresentati da barre bassissime (frequentemente un singolo campione, 10^0), confermando la loro natura di eventi isolati, anomali e incompatibili con la misurazione biologica standard.




Figura 1: Distribuzione delle 14 feature EEG prima del preprocessing (Scala Logaritmica su asse Y).

Boxplot pre-processing a scala completa

L'effetto degli outlier risulta ancora più evidente nei boxplot mostrati in Figura 2.

I box risultano completamente schiacciati verso lo zero poiché la scala è dominata da pochi valori estremi, visibili come punti isolati molto distanti dalla massa principale dei dati.




Figura 2: Boxplot delle feature EEG prima del preprocessing con scala completa.

Boxplot pre-processing con scala limitata

Limitando la scala verticale a $10.000 \mu V$, come mostrato nella Figura 3, emerge chiaramente la struttura reale delle distribuzioni.

I box risultano compatti e centrati nell'intervallo compreso tra 4.000 e $4.700 \mu V$, mentre gli outlier fisiologicamente plausibili appaiono come punti isolati vicini ai baffi del boxplot.




Figura 3: Boxplot delle feature EEG prima del preprocessing con scala limitata a 10.000 μV .

Per il trattamento degli outlier è stato adottato il metodo IQR, basato sul primo quartile (Q_1) e sul terzo quartile (Q_3), statistiche robuste rispetto alla presenza di valori estremi.

Sul Training Set sono state rimosse le osservazioni anomale, mentre sul Test Set è stato applicato il clipping utilizzando i limiti calcolati sui dati di addestramento, preservando così l'integrità del campione di test.

3.4 Analisi delle correlazioni e della covarianza

3.4.1 Analisi pre-cleaning

La matrice di correlazione di Pearson calcolata prima della rimozione degli outlier mostra alcune correlazioni apparentemente molto elevate tra coppie di sensori, con valori prossimi a 0.99. Tali correlazioni risultano tuttavia artificiali e sono causate dalla presenza degli outlier estremi, che alterano significativamente le statistiche di dipendenza lineare.


Allo stesso modo, la matrice di covarianza pre-cleaning presenta valori dell'ordine di 10^7 , risultando fortemente distorta e inaffidabile per qualsiasi tipo di analisi esplorativa.

3.4.2 Analisi post-cleaning


Dopo la procedura di pulizia (rimozione degli outlier tramite IQR sul Training Set), le matrici mostrano una struttura coerente e significativamente più informativa.

Nella matrice di correlazione post-cleaning, nessuna coppia di sensori presenta valori superiori a 0.86. Le correlazioni più elevate osservate, come AF3–AF4 ($r = 0.86$) e F3–F4 ($r = 0.73$), risultano fisiologicamente coerenti con la vicinanza anatomica e speculare degli elettrodi sullo scalpo e non indicano una ridondanza informativa critica.

Parallelamente, la scala della matrice di covarianza si riduce da valori dell'ordine di 10^7 a circa 400, con una diminuzione superiore a quattro ordini di grandezza. Le matrici ottenute dopo il preprocessing riflettono quindi la reale struttura topografica e di dipendenza tra i segnali EEG, costituendo una base solida per lo sviluppo dei modelli.




(a) Pre-Cleaning




(b) Post-Cleaning

Figura 4: Confronto delle matrici di Correlazione di Pearson prima e dopo la rimozione degli outlier.



(a) Pre-Cleaning (Scala 10^7)



(b) Post-Cleaning (Scala 400)

Figura 5: Confronto delle matrici di Covarianza prima e dopo la rimozione degli outlier.

3.5 Analisi della dimensionalità (PCA)

L'applicazione della Principal Component Analysis (PCA) sul Training Set standardizzato ha permesso di esplorare visivamente la complessità geometrica del problema.

Distribuzione della varianza (Scree Plot) Lo *Scree Plot* (Figura 6) dimostra che la prima componente principale spiega solo il 46.42% della varianza totale. Per raggiungere una copertura del 95% è necessario mantenere 10 componenti, mentre per il 99% ne occorrono 13.

Questo conferma visivamente che l'informazione sullo stato oculare non è dominata da uno o due sensori, ma è distribuita su quasi tutti gli elettrodi. Tale evidenza giustifica la decisione di mantenere l'intero set di feature (14 canali) per l'addestramento dei modelli geometrici e gerarchici (SVM e Decision Tree).




Figura 6: Scree Plot: Analisi della varianza spiegata sulle componenti principali.

Analisi della separabilità (Scatter Plot) La proiezione dei campioni sulle prime due componenti principali (Figura 7) evidenzia una densa sovrapposizione tra i campioni della classe *Open* e quelli della classe *Closed*.

L'assenza di cluster visivamente distinti e separabili mediante una linea retta costituisce la prova empirica della natura fortemente non lineare del problema. Questa osservazione giustifica l'utilizzo di algoritmi in grado di tracciare confini decisionali complessi, come le Support Vector Machines con Kernel RBF o gli Alberi Decisionali.




Figura 7: Proiezione 2D dei dati EEG sulle prime due Componenti Principali.

4 Descrizione e logica dei modelli di Machine Learning scelti

L'obiettivo di questa sezione è descrivere i modelli selezionati per la classificazione dello stato oculare (*Open* vs *Closed*) a partire dai segnali EEG. La strategia adottata prevede l'impiego di tre algoritmi con logiche differenti: un approccio probabilistico (Naive Bayes), uno gerarchico (Decision Tree) e uno geometrico (SVM).

Prima dell'applicazione dei modelli, è stata definita una soglia di riferimento (*Baseline* statistica) per poter valutare oggettivamente l'effettivo guadagno prestazionale garantito dagli algoritmi di apprendimento.

4.1 Gaussian Naive Bayes (con PCA)

Rappresenta il primo approccio probabilistico, utilizzato come benchmark per verificare la separabilità delle classi basata sulla distribuzione statistica dei dati.

Teoria e Funzionamento L'algoritmo rappresenta un approccio probabilistico basato sul Teorema di Bayes. L'aggettivo *Naive* (ingenuo) deriva dall'assunzione semplificativa di indipendenza condizionale tra le feature: il modello assume matematicamente che la presenza di una caratteristica sia totalmente slegata dalla presenza di un'altra. Per soddisfare questa assunzione, il modello è stato accoppiato alla Principal Component Analysis (PCA): non lavora sui sensori originali correlati, ma sulle 10 componenti ortogonali estratte, semplificando drasticamente e in modo corretto il calcolo delle probabilità.

Assunzione di Gaussianità e Scaling Trattandosi di feature continue, è stata utilizzata la variante *Gaussian NB*, che assume che i valori in ingresso seguano una distribuzione normale. Il modello apprende quindi la media e la varianza per le due classi. Sebbene il Naive Bayes sia intrinsecamente meno sensibile alla scala rispetto ai modelli basati su distanze, l'incapsulamento in una *Pipeline* con lo *StandardScaler* garantisce che il calcolo delle probabilità non sia influenzato da differenze di ampiezza residue, fornendo un input stabile alla PCA e migliorando la precisione numerica durante la fase di inferenza.

4.2 Decision Tree

Il modello basato su alberi decisionali è stato scelto per la sua natura gerarchica, che permette di mappare il segnale EEG attraverso una serie di regole booleane sequenziali, rendendo il processo di classificazione estremamente interpretabile dal punto di vista clinico.

Logica di funzionamento e Indice di Gini Il funzionamento del modello si basa su una procedura di suddivisione ricorsiva: partendo dal nodo radice, l'algoritmo esamina ogni sensore (*feature*) e ogni possibile soglia di voltaggio per frammentare i dati in nodi figli progressivamente più "puri". Per identificare lo *split* ottimale ad ogni passaggio, è stato utilizzato l'*Indice di Gini* come criterio di impurezza. Questa misura quantifica la probabilità di errore nella classificazione casuale di un elemento in un nodo; l'algoritmo seleziona la suddivisione che massimizza la diminuzione di tale indice, cercando di separare i campioni *Open* da quelli *Closed* nel modo più netto possibile.

Invarianza di scala Una caratteristica distintiva di questo approccio è l'invarianza rispetto alla scala dei dati. Poiché l'albero valuta una variabile alla volta in modo isolato per determinare la soglia di taglio, non risente delle differenti ampiezze tra i vari sensori. Non applicando alcuno *scaler*, l'albero mantiene la capacità di fornire soglie decisionali direttamente espresse nella metrica originale (μV), permettendo di mappare la risposta del modello direttamente sulla topografia cerebrale.

4.3 Support Vector Machines (SVM)

Le Support Vector Machines rappresentano l'approccio geometrico volto a individuare l'iperpiano di separazione ottimale tra le classi. Data la natura multidimensionale dei segnali EEG (14 canali), le SVM risultano particolarmente efficaci nel gestire spazi di feature complessi.

Logica del Margine Massimo e Support Vectors L'obiettivo delle SVM è individuare il confine di decisione che massimizzi il margine, ovvero la distanza tra il confine stesso e i punti più vicini di ogni classe, denominati *Support Vectors*. La scelta di massimizzare il margine è una precisa strategia progettuale: un margine più ampio riduce il rischio che fluttuazioni casuali o rumore nel segnale bio-elettrico portino a errori di classificazione.

Necessità dello StandardScaler Poiché le SVM si basano geometricamente sul calcolo delle distanze euclidee, l'applicazione dello **StandardScaler** all'interno della **Pipeline** è stata obbligatoria. Feature con ordini di grandezza molto differenti avrebbero distorto il calcolo della distanza, rendendo il modello dipendente esclusivamente dalla feature con i valori numericamente più alti.

Kernel Lineare e Kernel RBF Sono stati testati due approcci:

- **Kernel Lineare:** Cerca una separazione tramite un iperpiano piatto. È stato utilizzato come *baseline* geometrica per confermare l'impossibilità di risolvere il problema con una semplice combinazione lineare dei sensori.
- **Kernel RBF (Radial Basis Function):** Attraverso il cosiddetto *Kernel Trick*, proietta matematicamente i dati in uno spazio a infinite dimensioni dove è possibile trovare un iperpiano di separazione. Questo permette di riproiettare confini di decisione curvi e complessi nello spazio originale, ideali per separare le classi quando queste risultano sovrapposte o mescolate.

Tuning del Parametro di Regolarizzazione (C) Per il kernel RBF, le performance sono state ottimizzate ricercando il miglior parametro C . Questo iperparametro controlla il *trade-off* tra la larghezza del margine e il numero di errori ammessi sul training set. Un valore di C elevato (margine *hard*) tenta di classificare correttamente tutti i punti di addestramento ma rischia l'overfitting; un valore di C più contenuto definisce un margine *soft*, che accettando alcuni errori di classificazione nel training set, favorisce una migliore capacità di generalizzazione del sistema.

5 Campagna sperimentale

La campagna sperimentale è stata progettata con l'obiettivo di valutare la capacità dei modelli di classificare correttamente lo stato oculare, confrontando approcci probabilistici, gerarchici e geometrici. L'intero processo è stato strutturato per garantire solidità metodologica, assenza di *data leakage* e robustezza statistica.

5.1 Preparazione del dataset

Come spiegato nei capitoli precedenti, la campagna sperimentale ha rispettato la suddivisione originale tra Training Set (9.980 istanze) e Test Set (5.000 istanze). Il Test Set è stato mantenuto isolato per la misurazione finale delle performance. Tutte le analisi preventive (correlazione, varianza e PCA) sono state eseguite esclusivamente sul Training Set post-cleaning. Avendo appurato che tutti i 14 sensori presentano una varianza sufficiente e che non vi è multicollinearità critica (nessuna correlazione superiore alla soglia critica di 0.95, con il valore massimo osservato di 0.86 tra AF3 e AF4), l'esperimento ha proceduto mantenendo l'intero spazio delle feature.

5.2 Preprocessing e Pipeline

Per preparare i dati all'addestramento, sono state adottate strategie di preprocessing differenziate, implementate in modo da prevenire qualsiasi contaminazione dei dati (*data leakage*):

Gestione degli Outlier (IQR) La rimozione e il *clipping* basati sui limiti IQR sono stati eseguiti prima di ogni fase di training. I bound sono stati calcolati matematicamente ed esclusivamente sul Training Set. Di conseguenza, il Training Set è stato ripulito fisicamente dai campioni anomali, mentre al Test Set (e ai Validation fold) è stato applicato il clipping.

Standardizzazione e Pipeline L'applicazione dello **StandardScaler** è obbligatoria per la corretta convergenza del margine geometrico nelle SVM ed è necessaria al Naive Bayes per stabilizzare le distribuzioni prima di applicare la PCA. Per gestire queste trasformazioni in totale sicurezza, **sia le SVM che il Naive Bayes sono stati incapsulati in oggetti Pipeline di Scikit-Learn.**

Invarianza del Decision Tree Il Decision Tree valuta le soglie di *split* in modo indipendente per ogni feature. Essendo intrinsecamente invariante alla scala dei dati, è stato addestrato ricevendo in input direttamente i dati grezzi puliti.

5.3 Definizione della Baseline

Per valutare l'effettivo valore aggiunto degli algoritmi di Machine Learning, è stato prima definito un classificatore euristico di base (*Baseline*), che assegna sistematicamente ogni campione alla classe maggioritaria del Test Set ("Occhio Aperto", target = 0). Tale approccio banale produce un'accuracy del 53.48%. Questo valore rappresenta la soglia di sbarramento: un modello che non la superi significativamente non starebbe estraendo alcun pattern dal segnale EEG.

5.4 Strategia di ottimizzazione dei modelli (Hyperparameter Tuning)

Per massimizzare la capacità di generalizzazione e prevenire l'overfitting, per ciascun modello è stata adottata una specifica strategia di ottimizzazione degli iperparametri, mantenendo sempre il Test Set rigorosamente isolato.

Support Vector Machines Durante le prime fasi di sperimentazione, è stato condotto un test preliminare (*Vanilla Test*) valutando le SVM con parametri di default. La SVM con Kernel Lineare ha mostrato performance modeste a fronte di tempi di calcolo molto elevati. Si è quindi deciso di non procedere a una costosa *Grid Search* per il modello lineare, confermandone l'inadeguatezza strutturale per questo dominio non lineare.

Tutte le risorse computazionali sono state quindi investite nell'ottimizzazione della **SVM con Kernel RBF**. È stata effettuata una *5-fold Cross-Validation* sul Training Set per testare il parametro di regolarizzazione $C \in \{0.1, 1, 10, 100\}$. La scelta del miglior C è avvenuta selezionando il valore con l'accuracy media più elevata sui 5 fold:

- $C = 0.1 \rightarrow$ Accuracy media CV: 0.8756
- $C = 1 \rightarrow$ Accuracy media CV: 0.9310
- $C = 10 \rightarrow$ Accuracy media CV: 0.9633
- $C = 100 \rightarrow$ Accuracy media CV: 0.9658

Il valore ottimale individuato è stato $C = 100$, assicurando che la configurazione geometrica finale non fosse influenzata da una singola suddivisione fortunata dei dati.

Decision Tree: Cost Complexity Pruning Per l'albero decisionale è stata utilizzata la tecnica del *Cost Complexity Pruning*. L'algoritmo ha percorso l'intero percorso di potatura (**ccp_alphas**) sul sottoinsieme di addestramento, generando centinaia di configurazioni dell'albero caratterizzate da differenti livelli di complessità e profondità.

Per individuare il parametro di penalità α ottimale, ogni singola configurazione è stata validata sul Validation Set (20% del Training Set originario, pari a 1.996 campioni), estratto preventivamente tramite campionamento stratificato. Questo metodo ha permesso di valutare il *trade-off* tra bias e varianza su dati mai visti durante il *fit*, evitando che l'albero memorizzasse il rumore (*overfitting*). Il parametro ottimale individuato è stato $\alpha = 0.000642$, corrispondente al picco di accuracy sul Validation Set.

Gaussian Naive Bayes Sebbene il Gaussian Naive Bayes non disponga di iperparametri complessi da ottimizzare tramite Cross-Validation, la strategia di ottimizzazione si è concentrata sulla preparazione matematica del suo spazio di input. Più che sui parametri dell'algoritmo, si è agito applicando la **PCA a 10 componenti** all'interno della sua **Pipeline**. Questa trasformazione ha "ottimizzato" i dati rendendoli ortogonali, permettendo al modello probabilistico di performare al meglio rispettando l'assunzione di indipendenza condizionale.

5.5 Protocollo di Valutazione sul Test Set

Dopo la selezione degli iperparametri ottimali, i modelli definitivi sono stati addestrati sull'intero Training Set (ripulito) e valutati sul Test Set (clippato).

Per ciascun classificatore sono state calcolate le seguenti metriche di performance:

- **Accuracy:** misura globale di correttezza delle predizioni;
- **Precision:** proporzione di identificazioni corrette di uno specifico stato oculare sul totale delle predizioni positive;
- **Recall:** capacità di intercettare correttamente le istanze reali di una determinata classe;
- **F1-score:** media armonica tra Precision e Recall, fondamentale per bilanciare le due componenti;
- **Confusion Matrix:** analisi dettagliata della distribuzione di veri positivi, veri negativi, falsi positivi e falsi negativi.

Per le SVM, è stato registrato inoltre il numero di *Support Vectors* come indicatore della complessità geometrica del modello.

5.6 Valutazione della Capacità Discriminante (Curve ROC e AUC)

Per valutare l'efficacia dei modelli indipendentemente dalla soglia fissa di classificazione (impostata di default al 50%), è stata prodotta una curva ROC comparativa.

Per tracciare la curva, sono state calcolate le probabilità di appartenenza alla classe positiva (*Closed*) utilizzando il metodo `predict_proba()`. Il calcolo dell'Area Sotto la Curva (AUC) associato a ogni modello fornisce un parametro numerico sintetico e indipendente: un valore vicino a 1 indica una capacità discriminativa eccellente, mentre un valore di 0.5 corrisponde al caso casuale.

5.7 Analisi dell'Efficienza Computazionale

Per contestualizzare l'applicabilità dei modelli in uno scenario di monitoraggio in tempo reale, sono stati misurati i tempi di *training*. La misurazione è stata effettuata calcolando la differenza temporale tra l'istante immediatamente precedente e successivo alla chiamata del metodo `fit()`. Per SVM e Naive Bayes il tempo registrato comprende l'esecuzione dell'intera *Pipeline* (inclusi `StandardScaler` e `PCA`), mentre per il Decision Tree valuta il *fitting* diretto. Questo permette di confrontare il costo reale e complessivo dell'architettura scelta per ogni algoritmo.

5.8 Validazione Statistica (Repeated Stratified Cross-Validation)

Per superare i limiti di confidenza legati all'utilizzo di un singolo *split* Train/Test, è stata progettata una campagna di validazione statistica intensiva. I dati puliti di Training e Test sono stati uniti in un singolo corpus di 11.462 campioni.

Su tale dataset è stata eseguita una *Repeated Stratified Cross-Validation* (`RepeatedStratifiedKFold`) con 10 fold ripetuti 5 volte, per un totale di 50 iterazioni per modello. L'incapsulamento degli algoritmi all'interno delle *Pipeline* ha garantito che in ogni singola iterazione lo *scaling* e l'estrazione delle componenti principali (PCA) venissero ricalcolati esclusivamente sul sottoinsieme di training di quel fold. Per ogni modello è stata calcolata la media dell'accuracy sulle 50 iterazioni e l'intervallo di confidenza al 95% tramite t-test.

6 Analisi dei risultati

In questa sezione vengono esaminati i risultati puntuali ottenuti dai diversi modelli di classificazione sul Test Set. L'analisi segue un percorso incrementale, partendo dalla *baseline* statistica per poi valutare l'efficacia e i limiti degli algoritmi di Machine Learning ottimizzati.

6.1 Modello di Baseline

Come definito nella metodologia, è stato calcolato un riferimento di confronto tramite un classificatore euristico che assegna sistematicamente ogni campione alla classe maggioritaria (*Open*, target = 0). Tale approccio non estrae alcun pattern dal segnale EEG, ma si limita a sfruttare lo sbilanciamento naturale del dataset.

La *baseline* ottiene un'accuracy di **0.5348**. Questo valore costituisce la soglia minima di validazione: qualsiasi modello sviluppato deve superare tale limite per dimostrare di aver effettivamente appreso informazione bio-elettrica utile. Tutti i modelli addestrati in questa campagna sperimentale superano ampiamente tale soglia.

6.2 Gaussian Naive Bayes

Il Gaussian Naive Bayes, addestrato sullo spazio latente generato dalla PCA a 10 componenti, ha raggiunto un'accuracy sul Test Set pari a **0.6320**, superando la *baseline* di quasi 10 punti percentuali.

Il *classification report* evidenzia un comportamento bilanciato e simmetrico nella rilevazione dei due stati oculari:

- **Classe "Open"**: Precision 0.66, Recall 0.64 (F1-score = 0.65).
- **Classe "Closed"**: Precision 0.60, Recall 0.63 (F1-score = 0.61).

L'impiego della PCA all'interno della *Pipeline* ha permesso di fornire al modello feature ortogonali, rispettando appieno l'assunzione di indipendenza condizionale richiesta dal Teorema di Bayes. Di conseguenza, le performance limitate (seppur nettamente superiori al caso casuale) non sono imputabili a violazioni delle assunzioni statistiche, bensì alla topologia intrinseca dei dati.

Essendo le classi profondamente sovrapposte e non linearmente separabili (come dimostrato nello *Scatter Plot* esplorativo), un classificatore come il Naive Bayes — che traccia confini decisionali semplici in spazi gaussiani indipendenti — non possiede la flessibilità geometrica necessaria per catturare le relazioni non lineari che determinano lo stato oculare.

6.3 Decision Trees

L'impiego dell'albero decisionale ha permesso di approcciare il segnale EEG attraverso una logica gerarchica, capace di segmentare i dati in base a soglie di voltaggio specifiche. Mantenendo i dati nella loro scala originale (μV), l'algoritmo ha preservato la totale interpretabilità clinica. La sperimentazione è stata articolata in due fasi per bilanciare la capacità di apprendimento (*fitting*) con la necessità di generalizzazione.

6.3.1 Albero Completo

L'albero decisionale addestrato senza vincoli di potatura raggiunge un'accuracy sul Test Set di **0.7746**, con un *classification report* equilibrato (F1 *Open* = 0.79, F1 *Closed* = 0.75). Si tratta di un salto prestazionale netto rispetto al Naive Bayes (+14 punti percentuali), a conferma di come la struttura gerarchica sia più adatta a catturare i pattern del segnale EEG.

Il nodo radice utilizza il sensore frontale AF4 come primo split, confermando l'importanza di questo elettrodo nell'intercettare i segnali oculari. Tuttavia, la complessità dell'albero completo risulta critica: presenta una profondità di 24 livelli e 1319 nodi complessivi. Un albero di questa dimensione perde ogni utilità interpretativa e, soprattutto, cattura inevitabilmente il rumore di fondo e gli artefatti residui presenti nei dati di addestramento (*overfitting*), generando regole troppo specifiche per generalizzare su nuovi soggetti.

6.3.2 Ottimizzazione tramite Cost Complexity Pruning

Per forzare la generalizzazione del modello, è stato applicato il *Cost Complexity Pruning*. L'algoritmo ha valutato 401 differenti valori del parametro di penalità α . Per ogni configurazione è stato addestrato un albero, misurandone poi le performance sul Validation Set indipendente.

Il grafico del *trade-off* (Figura 8) mostra il comportamento teorico atteso: con α prossimo a zero, l'accuracy sul Training Set è perfetta (1.0, memorizzazione totale del dataset), mentre sul Validation Set si ferma sotto lo 0.81, evidenziando un enorme *gap* dovuto all'*overfitting*. All'aumentare di α , vengono recisi i rami che modellano il rumore: l'accuracy di training scende, ma la stabilità del modello aumenta.

Il valore ottimale individuato per massimizzare la validazione è risultato $\alpha = 0.000642$, garantendo un'accuracy sul Validation Set del **0.8066**.




Figura 8: Trade-off Accuratezza vs α (Cost Complexity Pruning).

6.3.3 Risultati dell'Albero Finale (Post-Pruning)

L'albero addestrato con il parametro ottimale $\alpha = 0.000642$ presenta una profondità ridotta a 13 livelli e 281 nodi. Si tratta di una **riduzione del 78.70% della complessità strutturale** rispetto all'albero di partenza.

Valutato sul Test Set, questo modello semplificato ottiene un'accuracy di **0.7308** ($F1_{Open} = 0.75$, $F1_{Closed} = 0.71$). Sebbene si osservi un calo di circa 4 punti percentuali rispetto all'albero completo ($0.7746 \rightarrow 0.7308$), questo abbassamento va interpretato come il prezzo fisiologico della generalizzazione. L'albero completo raggiungeva il 77% sfruttando l'overfitting e memorizzando i micro-pattern rumorosi; l'albero potato, rinunciando a questa accuratezza "fittizia", restituisce un set di regole molto più robuste, applicabili e generalizzabili nel mondo reale.

L'interpretabilità di questo modello compatto è riassunta nella *Feature Importance* (Figura 9), la quale conferma che la classificazione si basa primariamente su una rete di elettrodi distribuiti (frontali e occipitali), coerentemente con l'assenza di un singolo sensore dominante.




Figura 9: Importanza delle feature nell'Albero Decisionale Ottimizzato.

6.4 Support Vector Machines (SVM)

L'approccio geometrico delle SVM rappresenta la fase più avanzata della modellazione, mirata a individuare l'iperpiano di separazione a massimo margine nello spazio multidimensionale dei 14 sensori EEG.

6.4.1 SVM con Kernel Lineare

Come descritto nella strategia di ottimizzazione, la SVM con kernel lineare è stata valutata inizialmente con parametri di default per testare l'effettiva separabilità lineare dello spazio delle feature.

Le performance sul Test Set si sono fermate a un'accuracy modesta di **0.6396** (Precision media 0.64, Recall media 0.64). Questo risultato empirico ha confermato quanto già suggerito dall'analisi della varianza (PCA): le classi *Open* e *Closed* non sono linearmente separabili.

In ottica di ottimizzazione delle risorse computazionali, si è deciso di non procedere con una dispendiosa *Grid Search* su questo modello. Un classificatore lineare si rivela strutturalmente inadeguato per tracciare un confine netto tra le classi in questo specifico dominio.

6.4.2 SVM con Kernel RBF

La SVM con kernel RBF, valutata nel medesimo test iniziale, ha mostrato immediatamente un potenziale superiore, raggiungendo un'accuracy di partenza dello **0.7528**. Questa evidenza ha giustificato l'investimento computazionale per il *tuning* degli iperparametri.

La *Cross-Validation* sul Training Set ha esplorato diversi valori del parametro di regolarizzazione C , individuando il valore ottimale in $C = 100$, che ha generato un'accuracy media in validazione pari allo **0.9658**.

Valutato sul Test Set indipendente, il modello RBF ottimizzato restituisce le seguenti metriche definitive:

- **Accuracy:** 0.7700
- **Classe "Open":** Precision 0.76, Recall 0.83, F1-Score 0.79
- **Classe "Closed":** Precision 0.78, Recall 0.70, F1-Score 0.74

L'analisi di questi risultati porta a due considerazioni tecniche:

1. **Il Margine Hard:** Il numero ridotto di Support Vectors (893 su 6.462, pari al 13.8%) indica che il kernel RBF, proiettando i dati in uno spazio ad alta dimensionalità, riesce a trovare una frontiera di separazione più netta rispetto al kernel lineare (3.601 support vectors, 55.7%), confermando la superiorità geometrica dell'approccio non lineare.
2. **Il divario tra CV e Test Set:** Emerge un evidente scarto prestazionale tra l'accuracy stimata dalla Cross-Validation (0.9658) e quella reale misurata sul Test Set (0.7700). Tale divario non è imputabile a un banale overfitting sui parametri, ma suggerisce la presenza di una forte autocorrelazione nel segnale continuo (*Data Leakage Temporale*). Durante la CV, il mescolamento casuale dei dati inserisce istanti temporali consecutivi (e quasi identici) in fold diversi, permettendo al modello di avere un'accuratezza artificialmente elevata. Il Test Set, mantenuto isolato, restituisce invece la reale capacità di generalizzazione del modello (0.7700), confermando comunque il Kernel RBF come l'algoritmo geometricamente più potente per questo dataset.

6.5 Analisi Comparativa

6.5.1 Confronto delle Performance sul Test Set

La tabella seguente riassume le metriche prestazionali puntuali calcolate in modo rigoroso sul Test Set isolato per tutti i modelli sviluppati.

Al fine di valutare correttamente il comportamento globale dei classificatori tenendo conto del lieve sbilanciamento naturale del dataset (56.9% *Open*, 43.1% *Closed*), i valori riportati per le metriche di *Precision*, *Recall* e *F1-Score* rappresentano la media pesata (*weighted average*) tra le prestazioni ottenute sulle singole classi.

Modello	Accuracy	Precision	Recall	F1-Score	AUC
Baseline	0.5348	—	—	—	—
Gaussian NB (PCA)	0.6320	0.63	0.63	0.63	0.6763
SVM Lineare	0.6396	0.64	0.64	0.64	0.6640
Decision Tree	0.7308	0.73	0.73	0.73	0.7539
SVM RBF	0.7700	0.77	0.77	0.77	0.8206

Tabella 1: Riassunto delle performance sul Test Set isolato.

6.5.2 Analisi dell'Efficienza Computazionale

Un fattore decisivo per l'applicabilità clinica o tecnologica in tempo reale è il tempo di addestramento e inferenza dell'architettura. I dati mostrano un divario evidente legato alla complessità algoritmica:

Modello	Tempo di Training (s)
Gaussian NB (con PCA)	0.0103
Decision Tree	0.1071
SVM RBF	6.8101
SVM Lineare	12.9371

Tabella 2: Tempi di esecuzione delle Pipeline di addestramento.

Il **Naive Bayes** (0.01s) e il **Decision Tree** (0.10s) risultano i modelli più rapidi, al contrario, le SVM presentano costi computazionali superiori. La **SVM Lineare** richiede quasi 13 secondi, risultando il modello più lento in assoluto, il che, unito alle performance inferiori, ne decreta l'inefficienza totale. La **SVM RBF** offre invece un eccellente compromesso: pur richiedendo circa 6.8 secondi di addestramento, restituisce la massima accuratezza sul Test Set.

6.5.3 Analisi della Capacità Discriminante (Curve ROC)

L'analisi dell'area sottostante la curva ROC (AUC) permette di valutare la separazione tra le classi al variare della soglia probabilistica:

- **SVM RBF (AUC: 0.8206)**: Conferma la sua supremazia, mostrando la miglior capacità di ordinamento dei campioni e un'ottima robustezza nel minimizzare i falsi positivi.
- **Decision Tree (AUC: 0.7539)**: Si posiziona al secondo posto. Pur avendo una buona accuratezza puntuale, la sua curva ROC riflette la natura (discreta) delle regole foglia.
- **Gaussian NB (AUC: 0.6763) e SVM Lineare (AUC: 0.6640)**: Grazie all'estrazione di feature ortogonali (PCA), il Naive Bayes supera leggermente la SVM Lineare in termini di capacità discriminante globale, dimostrando che uno spazio probabilistico indipendente approssima il segnale marginalmente meglio di un iperpiano rigido.




Figura 10: Confronto delle Curve ROC tra i modelli valutati.

6.5.4 Validazione Statistica e Discussione Critica dell'Anomalia Riscontrata

Per studiare la stabilità dei modelli al variare dei campioni, è stata condotta la *Repeated Stratified Cross-Validation* (50 valutazioni per modello) sull'intero corpus di dati disponibile, i cui risultati sintetici sono raccolti nella Tabella 3.

Modello	Media Accuracy (50 fold)	IC 95%
Gaussian NB (PCA)	0.7036	(0.7000 – 0.7073)
SVM Lineare	0.7113	(0.7079 – 0.7146)
Decision Tree	0.8181	(0.8150 – 0.8212)
SVM RBF	0.9652	(0.9636 – 0.9667)

Tabella 3: Risultati della Repeated Stratified Cross-Validation.

Il confronto incrociato tra i risultati della Cross-Validation e quelli precedentemente misurati sul Test Set isolato (Sezione 6.5.1) evidenzia una macroscopica anomalia prestazionale. In particolare, la SVM RBF sperimenta un incremento drastico dell'accuratezza, che schizza dal 77.00% sul Test Set a un quasi

perfetto **96.52%** in Cross-Validation. Un comportamento analogo, seppur più contenuto, si osserva per il Decision Tree (da 73.08% a 81.81%).

A fronte di questa evidente discrepanza, si rende necessaria una discussione critica. Non ritenendo verosimile un salto prestazionale così marcato dovuto esclusivamente alla natura dei fold, **avanziamo l'ipotesi interpretativa che l'esperimento di Cross-Validation sia influenzato da un fenomeno di Data Leakage Temporale.**

I segnali EEG sono, per definizione fisica, serie temporali continue caratterizzate da un'altissima frequenza di campionamento. Osservazioni registrate in millisecondi contigui presentano un'autocorrelazione statistica estremamente elevata, condividendo quasi lo stesso identico stato elettrico. Nel protocollo di Cross-Validation standard, l'intero dataset viene unito e mescolato casualmente prima della ripartizione nei 10 fold.

Si ipotizza che questo mescolamento distrugga la continuità temporale del segnale, frammentandolo: per un campione inserito nel fold di validazione all'istante t , è altamente probabile che gli istanti immediatamente precedenti ($t - 1$) o successivi ($t + 1$) siano stati allocati nel sottoinsieme di training dello stesso fold. Di conseguenza, algoritmi ad alta capacità geometrica e non lineari (come SVM RBF e Alberi Decisionali) potrebbero limitarsi a *memorizzare* il rumore locale e la vicinanza temporale dei punti, riconoscendoli nei fold di validazione e restituendo metriche artificialmente ottimistiche (96.5%).

Al contrario, il Test Set nativo fornito a monte — che esprime un'accuratezza reale del 77.00% — è stato verosimilmente isolato mantenendo intatta la separazione cronologica dei blocchi di registrazione.

7 Conclusioni e riflessioni critiche

Il percorso di sviluppo e validazione condotto in questo progetto ha permesso di trasformare un dataset EEG grezzo e pesantemente influenzato da artefatti in un sistema decisionale robusto e funzionale.

La scelta del "modello migliore", in ogni caso, non si esaurisce in un mero confronto numerico, ma deve essere guidata dal contesto applicativo.

7.1 Il Trade-off tra Precision e Recall

Nel corso dell'analisi, abbiamo osservato come l'*Accuracy* sia la metrica più bilanciata per descrivere globalmente la correttezza del sistema. Tuttavia, l'implementazione nel mondo reale richiede di valutare i costi associati a specifici errori di classificazione:

- **Falso Positivo (impatto sulla Precision):** Classificare erroneamente lo stato "occhi chiusi" quando il soggetto ha gli occhi aperti potrebbe causare l'attivazione involontaria di un comando in una Brain-Computer Interface (BCI), causando gravi problemi di sicurezza o frustrazione per l'utente.
- **Falso Negativo (impatto sulla Recall):** Non rilevare la chiusura degli occhi significa che il sistema ignora un segnale fisiologico di potenziale pericolo (come l'insorgenza di un colpo di sonno in un sistema di monitoraggio alla guida).

La configurazione del modello e la metrica da ottimizzare dipendono quindi dal dominio: in un sistema di sicurezza stradale o aeronautico si privilegia la *Recall* per non perdere nessun evento critico; in una BCI si privilegia la *Precision* per evitare comandi accidentali.

7.2 Scelta del modello in base al contesto applicativo

Sebbene l'analisi scientifica decreti la SVM RBF come vincitrice assoluta in termini di potere predittivo, la messa in produzione può variare in base ai vincoli hardware e di interpretabilità:

Massima Affidabilità (SVM RBF) Con un'accuracy reale del **77.00%** e un AUC di **0.8206**, la SVM RBF è il modello indiscutibilmente superiore. Grazie al *Kernel Trick*, è l'unico algoritmo capace di gestire efficacemente la non-linearità intrinseca della propagazione del segnale cranico. È la scelta naturale per applicazioni cliniche e diagnostiche dove le risorse computazionali non sono un vincolo e l'errore deve essere ridotto al minimo.

Efficienza su Dispositivi a Basso Consumo (Decision Tree) Se il sistema dovesse operare su dispositivi con risorse computazionali e batterie limitate, il Decision Tree rappresenterebbe il miglior compromesso. Con un'accuracy del **73.08%** e un tempo di addestramento di soli **0.10 secondi** (decine di volte più veloce della SVM), permette di mantenere un monitoraggio fluido con un impatto hardware minimo. Un ulteriore vantaggio è l'estrema **interpretabilità**: la mappa delle soglie e la *Feature Importance* mostrano esplicitamente quali elettrodi (in μV) stanno innescando l'allarme, rendendo il modello trasparente.

Il limite dei modelli probabilistici e lineari: Il **Gaussian Naive Bayes** (63.20%) ha dimostrato che, pur fornendo al modello uno spazio di feature perfettamente ortogonali e indipendenti, l'approccio probabilistico lineare non possiede la flessibilità geometrica per separare le classi. Allo stesso modo, la **SVM Lineare** (63.96%), a causa dell'incapacità di approssimare la frontiera di separazione, unita al costo computazionale più elevato in assoluto (**13 secondi**), si è rivelata il modello peggiore del progetto.

7.3 Sviluppi Futuri

Alla luce delle scoperte fatte, il sistema può essere ulteriormente evoluto affrontando la natura del segnale da due nuove prospettive:

Analisi Sequenziale L'ipotesi del *Data Leakage Temporale* ha confermato che l'autocorrelazione del segnale EEG è fortissima. Al momento, i nostri classificatori valutano ogni riga come un istante isolato e indipendente (approccio statico). Tuttavia, l'apertura e chiusura delle palpebre è un processo dinamico che dura frazioni di secondo. Un'evoluzione naturale del progetto consisterebbe nell'abbandonare i modelli stocastici tradizionali in favore di modelli capaci di analizzare *finestre temporali* e basare la predizione non su una fotografia isolata, ma sulla sequenza degli eventi immediatamente precedenti.

Filtraggio nel Dominio della Frequenza (Onde Alpha) Il dataset fornito contiene i valori grezzi di ampiezza del segnale nel dominio dello spazio e del tempo. Un miglioramento fisiologico enorme si otterrebbe passando al dominio della frequenza per isolare specifiche bande di frequenza. È noto in neurologia che la chiusura degli occhi genera un forte incremento della potenza delle onde *Alpha* (8-13 Hz) nella regione occipitale. Estrarre queste frequenze pre-modello permetterebbe agli algoritmi di concentrarsi unicamente sul comando biologico reale, ignorando in partenza i rumori di fondo ad alta e bassa frequenza.